

3-2. Inner products

내적은 벡터의 길이나 두 벡터 간의 각도 또는 거리 등과 같은 직관적인 기하학적 개념을 도입하기 위한 것입니다.

내적의 주요 목적은 벡터가 서로 직교(orthogonal)인지 확인하는 것입니다.

3.2.1 Dot Product

- 결과 값이 스칼라이기 때문에 이렇게 **scalar product** 라고 부릅니다.
- \mathbb{R}^n , n 차원 실수 공간

$$\mathbf{x}^\top \mathbf{y} = \sum_{i=1}^n x_i y_i .$$

3.2.2 General Inner Products

지금까지 한 개의 벡터를 다뤘습니다. → Linear Mapping

bilinear mapping : Ω 는 두 인자(벡터)에 대한 mapping 이며, 각 인자에 대해 **linear** 합니다.

vector space V 와 모든 $x, y, z \in V$ 와 $\lambda, \psi \in \mathbb{R}$ 에 대해 다음이 성립합니다.

$$\Omega(\lambda \mathbf{x} + \psi \mathbf{y}, \mathbf{z}) = \lambda \Omega(\mathbf{x}, \mathbf{z}) + \psi \Omega(\mathbf{y}, \mathbf{z}) \quad (3.6)$$

$$\Omega(\mathbf{x}, \lambda \mathbf{y} + \psi \mathbf{z}) = \lambda \Omega(\mathbf{x}, \mathbf{y}) + \psi \Omega(\mathbf{x}, \mathbf{z}) . \quad (3.7)$$

- (3.6) → 첫 번째 인자에 대한 Linear한지를 확인
- (3.7) → 두 번째 인자에 대한 Linear한지를 확인

정의 3.2 (Symmetric and Positive definite)

vector space V

$\Omega : V \times V \rightarrow \mathbb{R}$, 두 개의 벡터를 인자로 취해 하나의 실수로 매핑하는 bilinear mapping

- Symmetric (대칭성)
 - 모든 $x, y \in V$ 에 대해 다음을 만족한다면, symmetric(대칭성)이라고 합니다.
 - $\Omega(x, y) = \Omega(y, x)$
- Positive definite (양의 정부호)
 - 모든 $x \in V \setminus \{0\}$ 에 대해 다음을 만족한다면, positive definite(양의 정부호)라고 합니다.
 - $\Omega(x, x) = 0, \Omega(0, 0) = 0$

정의 3.3 (Inner product)

vector space V

$\Omega : V \times V \rightarrow \mathbb{R}$, 두 개의 벡터를 인자로 취해 하나의 실수로 매핑하는 bilinear mapping

- 위 두가지 조건(정의 3.2)을 모두 만족하는 bilinear mapping을 **Inner Product (내적)**이라고 부릅니다.
 - 기호로는 보통 $\langle x, y \rangle$ 을 사용합니다.
 - 이때, 벡터 공간 V 는 **Inner Product Space(내적 공간)** 라고 부릅니다.
 - $(V, \langle \cdot, \cdot \rangle)$

예시 3.3 (Inner Product That is Not the Dot Product)

벡터 공간 $V = \mathbb{R}^2$ 에서, Dot product가 아닌 내적을 정의했습니다.

$$\langle x, y \rangle := x_1 y_1 - (x_1 y_2 + x_2 y_1) + 2x_2 y_2 \quad (3.9)$$

우선 내적(inner product)가 되기 위해서는 세 가지 조건을 만족해야 합니다.

1. Bilinearity

a. $x = (x_1, x_2), y = (y_1, y_2), z = (z_1, z_2), \lambda, \psi \in \mathbb{R}$

▼ 첫 번째 인자

$$\left| \begin{array}{l} \langle \lambda x + \psi z, y \rangle = \lambda \langle x, y \rangle + \psi \langle z, y \rangle \end{array} \right.$$

$$\begin{aligned}
\langle x, \lambda y + \psi z \rangle &= x_1(\lambda y_1 + \psi z_1) - \\
&\quad [x_1(\lambda y_2 + \psi z_2) + x_2(\lambda y_1 + \psi z_1)] + 2x_2(\lambda y_2 + \psi z_2) \\
&= \lambda(x_1y_1 - x_1y_2 - x_2y_1 + 2x_2y_2) + \psi(x_1z_1 - x_1z_2 - x_2z_1 + 2x_2z_2) \\
&= \lambda\langle x, y \rangle + \psi\langle x, z \rangle
\end{aligned}$$

▼ 두 번째 인자

$$\begin{aligned}
\langle x, \lambda y + \psi z \rangle &= \lambda\langle x, y \rangle + \psi\langle x, z \rangle \\
\\
\langle x, \lambda y + \psi z \rangle &= x_1(\lambda y_1 + \psi z_1) - \\
&\quad [x_1(\lambda y_2 + \psi z_2) + x_2(\lambda y_1 + \psi z_1)] + 2x_2(\lambda y_2 + \psi z_2) \\
&= \lambda(x_1y_1 - x_1y_2 - x_2y_1 + 2x_2y_2) + \psi(x_1z_1 - x_1z_2 - x_2z_1 + 2x_2z_2) \\
&= \lambda\langle x, y \rangle + \psi\langle x, z \rangle
\end{aligned}$$

2. Symmetry

$$\begin{aligned}
\langle x, y \rangle &= x_1y_1 - (x_1y_2 + x_2y_1) + 2x_2y_2 \\
\langle y, x \rangle &= y_1x_1 - (y_1x_2 + y_2x_1) + 2y_2x_2 \\
&= x_1y_1 - (x_1y_2 + x_2y_1) + 2x_2y_2 = \langle x, y \rangle
\end{aligned}$$

3. Positive Definite

$$\begin{aligned}\langle x, x \rangle &= x_1^2 - 2x_1x_2 + 2x_2^2 = (x_1 - x_2)^2 + x_2^2 \\ (x_1 - x_2)^2 + x_2^2 &\geq 0 \\ \therefore \langle x, x \rangle &> 0 \quad \text{if } x \neq 0 \quad \text{and} \quad \langle 0, 0 \rangle = 0 \quad \checkmark \text{ 성립}\end{aligned}$$

3.2.3 Symmetric, Positive Definite Matrices

머신러닝에서 Symmetric, positive definite matrices는 중요한 역할을 합니다.

이 행렬은 내적(inner product)을 기반으로 정의되며, 커널 이론이나 행렬 분해에서 쓰입니다.

어떤 n -차원 벡터 공간 V 에서 내적은 $\langle \cdot, \cdot \rangle : V \times V \rightarrow \mathbb{R}$ 로 정의되어 있다고 가정합니다.

V 의 ordered Basis $B = (b_1, \dots, b_n)$ 에 대해, 모든 벡터 $x, y \in V$ 는 다음과 같이 표현할 수 있습니다.

$$x = \sum_{i=1}^n \psi_i b_i, \quad y = \sum_{j=1}^n \lambda_j b_j$$

내적의 bilinearity 에 의해 다음과 같은 성질이 성립합니다.

$$\langle x, y \rangle = \left\langle \sum_{i=1}^n \psi_i b_i, \sum_{j=1}^n \lambda_j b_j \right\rangle = \sum_{i=1}^n \sum_{j=1}^n \psi_i \langle b_i, b_j \rangle \lambda_j = \hat{x}^\top A \hat{y}, \quad (3.10)$$

- \hat{x}, \hat{y} : 벡터 x, y 의 기저 B 에 대한 좌표 벡터
- $A_{ij} := \langle b_i, b_j \rangle$: 기저 벡터들끼리의 내적값으로 구성된 행렬

또한 만약 내적이 대칭(Symmetric)이라면 $A = A^\top$, positive definite 라면 $\forall x \in V \setminus \{0\} : x^\top A x > 0$ 입니다.

만약 위 조건에서 $\forall x \in V \setminus \{0\} : x^\top A x \geq 0$ 이라면, A 는 symmetric, positive semidefinite라고 부릅니다.

예시 3.4 (Symmetric, Positive Definite Matrices)

Example 3.4 (Symmetric, Positive Definite Matrices)

Consider the matrices

$$\mathbf{A}_1 = \begin{bmatrix} 9 & 6 \\ 6 & 5 \end{bmatrix}, \quad \mathbf{A}_2 = \begin{bmatrix} 9 & 6 \\ 6 & 3 \end{bmatrix}. \quad (3.12)$$

\mathbf{A}_1 is positive definite because it is symmetric and

$$\mathbf{x}^\top \mathbf{A}_1 \mathbf{x} = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 9 & 6 \\ 6 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad (3.13a)$$

$$= 9x_1^2 + 12x_1x_2 + 5x_2^2 = (3x_1 + 2x_2)^2 + x_2^2 > 0 \quad (3.13b)$$

for all $\mathbf{x} \in V \setminus \{\mathbf{0}\}$. In contrast, \mathbf{A}_2 is symmetric but not positive definite because $\mathbf{x}^\top \mathbf{A}_2 \mathbf{x} = 9x_1^2 + 12x_1x_2 + 3x_2^2 = (3x_1 + 2x_2)^2 - x_2^2$ can be less than 0, e.g., for $\mathbf{x} = [2, -3]^\top$.

- \mathbf{A}_2 의 경우 $\mathbf{x} = [2, -3]^\top$ 일 경우에 positive definite를 만족하지 않습니다.

출처

- Mathematics for Machine Learning (<https://github.com/mml-book/mml-book.github.io>)
- https://blog.naver.com/walk_along/222187729940
- <https://junstar92.github.io/mml-study-note/2022/07/07/ch3-2.html>